

T8.1 - Calidad y gobernanza de datos

Calidad de datos

Calidad de un dato → aptitud para ser usado. Si son malos los datos, habrá consecuencias negativas.

La calidad se mide y se cuantifica.

Análisis de calidad de los datos

Análisis univariado:

- Valor mínimo y máximo
- Media, mediana, moda
- Tablas de frecuencia
- Gráficos

Análisis bivariado:

- Coeficiente de correlación
- Tablas de contingencia
- Scatter plots

Dimensiones de la calidad de datos

- **Precisión:** ¿qué tan *cercano a la realidad* es este dato?

Nombre	Apellido	e-mail	Cód. país	Total de gastos
Juan	Perezz	juan.perez@gmail.com	20	\$2000

Formato correcto, pero no se corresponde con la realidad observable

- **Compleitud:** los *datos no deben tener valores desconocidos*.

Nombre	Apellido	e-mail	Cód. país	Total de gastos
Juan	Perez	juan.perez@gmail.com	20	[null]

Falta el total de gastos

- **Consistencia:** las *reglas de negocio se mantienen* → los *datos tienen coherencia*.

Nombre	Apellido	e-mail	Cód. empresa	Dirección laboral
Juan	Perez	juan.perez@gmail.com	281	Av. Pres. Figueroa Alcorta 7350

Código	Razón Social	Dirección
281	UTDT	Juan Pablo Saenz Valiente 1021

No coinciden las direcciones

- **Validez:** *revisión de tipo de datos o claves foráneas*.

Nombre	Apellido	e-mail	Cód. país	Total de gastos
Juan	S@#S#@	hola@gmail	99	a

Cód. país	Nombre país
20	Argentina
21	Perú
22	Colombia

Respetar el tipo de datos (cadena de texto) pero no parece ser un apellido válido

@gmail no es un dominio válido

La clave foránea 99 no está presente en la tabla de países

"a" no es un monto válido

- **Puntualidad:** el dato debe estar *disponible on-demand*.
- **Unicidad:** no *guardar varias veces* el mismo dato.
- **Conformidad:** el dato debe estar en el *formato correcto*.
- **Accesibilidad:** el dato debe estar *disponible para los interesados*.

Gobernanza de datos

Ciclo de vida del dato



Create → Store → Use → Share → Archive → Destroy.

Gobernanza de datos

Gobernanza → es la *capacidad* de una organización de *asegurar que los datos sean de alta calidad*. Se implementan procesos y prácticas para gestionar efectivamente los datos.

La gobernanza abarca:

- Quiénes son los responsables de conseguirla.
- Cómo los datos van a ser almacenados, respaldados y protegidos.
- Normas sobre cómo serán utilizados.
- Controles y procedimientos de auditoría.

Alcanzar la calidad de datos

Pipelines de datos

Cuando se pasan datos entre dos equipos, estos *se deben validar* para que lleguen en el estado esperado.

Si el pasaje se hace en streaming, hay que validar continuamente el flujo, definiendo antes *qué hacer si alguna regla se rompe*.

Observabilidad

Observabilidad → *comprensión* que tiene una organización respecto a la *salud y desempeño de los datos* en sus sistemas.

A través de la observabilidad se alcanza y se mejora la calidad de los datos.

La observabilidad se logra mediante estas técnicas:

- Monitoreo automatizado
- Análisis de causa raíz
- Linaje de datos

Estas técnicas se usan para prevenir, detectar y resolver anomalías.

Entre más se tarda en detectar una anomalía, peor es la consecuencia.