

## T8.2 - Privacidad y compliance

### Introducción

Un dato recorre un *camino* desde que *se adquiere hasta que se descarta*.

**Data Governance Lead** → define la estrategia de organización en cuanto a la gobernanza de los datos.

Una organización debe *cumplir ciertas normativas* respecto a la *protección de datos personales*. Quien se encarga de esta tarea a diario es el **data steward**.

### Catálogos

**Data catalogs** → son metadatos curados que refleja qué datos tiene una organización, quién los usa y dónde se los guarda.

### Designing a Data Catalog

Los **data catalogs** funcionan como un *inventario de metadatos* y dan a los interesados la *información necesaria para evaluar* la accesibilidad, la salud y la ubicación de los datos. También pueden *integrarse con machine learning* y automatización para hacer los datos más descubribles, colaborativos y en cumplimiento con regulaciones organizacionales o gubernamentales.

Los catálogos de próxima generación *tendrán la capacidad de aprender, entender e inferir los datos*, permitiendo a los usuarios aprovechar sus insights de forma self-service. También soportarán *automated data discovery y active metadata*.

**Data discovery** *reemplaza la necesidad de un data catalog al proveer un entendimiento dinámico y específico del dominio de los datos*, basado en cómo se ingestan, almacenan, agregan y usan. A diferencia del catálogo, el data discovery muestra el estado actual y en tiempo real de los datos, no su estado ideal o "catalogado". Los estándares de gobernanza se federan entre dominios, permitiendo mayor accesibilidad e interoperabilidad.

### Data Discovery defined

**Data discovery** es el proceso de *extraer insights y patrones significativos de grandes volúmenes de datos*. No se trata de recolectar más datos, sino de *darle sentido a los datos que ya se tienen* y transformarlos en conocimiento que guíe la estrategia de negocio.

Uber opera en más de 10.000 ciudades, en más de 69 países, 24 horas al día. A esa escala global, sus actividades generan grandes cantidades de datos operacionales y de logging en tiempo real (demanda de consumidores, disponibilidad de conductores, pagos, notificaciones, etc.).

Para ayudar a sus equipos a descubrir y entender estos datos, Uber construyó **Databook**, su plataforma interna que expone y gestiona los metadatos de datasets, dashboards internos, métricas de negocio, entre otros.

A medida que Uber creció, sus sistemas se volvieron más complejos y las necesidades de sus equipos también. Databook no pudo escalar para cubrir esas nuevas necesidades, lo que llevó a replantear la herramienta y reconstruirla.

## Arriving at a Data Democratization through Data Discovery

*Escalar la fluidez en datos y la descubribilidad de datos van de la mano*, ya que los analistas necesitan acceso fácil a los datos para tomar decisiones informadas.

*Niveles de madurez* en una organización:

1. **Data reactive** → *Nadie accede ni usa datos en su trabajo diario*. La empresa rara vez reporta o presenta datos.
2. **Data scaling** → Muy *pocas personas tienen las habilidades y el acceso necesario* para analizar, reportar y presentar datos con confianza.
3. **Data progressive** → Cada equipo tiene al menos *un empleado fluido* en datos que puede analizar, reportar y presentar datos, sin importar su rol.
4. **Data fluent** → *Todos saben cómo acceder a los datos que necesitan para hacer su trabajo* (esto no significa que todos necesiten saber programar).

---

## Aspectos legales de la protección de datos

### Información sensible

Las empresas de la economía digital *manejan bases de datos con información sensible* de los ciudadanos. Algunos países han *promovido normativas* para la protección de los ciudadanos respecto al almacenamiento y uso de sus datos personales.

**PII (Personally Identifiable Information)** → información que permitiría identificar en forma directa a un individuo. Ejemplos: nombre, dirección, CUIT, teléfono, e-mail.

# Prioritizing Data Governance and Compliance

**Data governance** se refiere al *proceso de mantener la disponibilidad, usabilidad, proveniencia y seguridad de los datos*. Tradicionalmente se lo ve como la "carta para que el CFO no termine preso".

El problema principal es que *los enfoques tradicionales no escalan con las necesidades de los data stacks basados en la nube*. En los últimos años, los **data catalogs** emergieron como una herramienta poderosa para data governance.

Los *data catalogs* pueden almacenar metadatos que dan a los stakeholders un mejor *entendimiento del linaje* de una fuente de datos, generando mayor confianza. También facilitan el rastreo de dónde se aloja la PII, hacia dónde puede propagarse downstream, y quién tiene permisos de acceso a lo largo del pipeline.

Hay distintos tipos de data catalogs automatizados.

## In-house

Algunas empresas B2C (como Airbnb, Netflix, Uber) *construyen sus propios data catalogs* para asegurar el cumplimiento con regulaciones a nivel estatal, nacional e incluso de uniones económicas.

## Third-party

Tradicionalmente, *los catálogos se manejaban manualmente y se gobernaban en silos*, requiriendo trabajo duplicado entre analistas y equipos de data science. Ahora existen catálogos potenciados por ML que se prestan a una gobernanza distribuida, muchos con integraciones de compliance y gestión de workflows. *Proveedores* cloud como Google, AWS y Azure también ofrecen herramientas de data governance como integración adicional.

## Open Source

En 2018, Lyft hizo open source su motor de data discovery y metadata llamado **Amundsen**. Otras herramientas open source incluyen Apache Atlas, Magda y CKAN, que proveen funcionalidades similares.

## Antecedentes de la protección de datos

- **1890** → Ya en esa época se advertía sobre cómo las fotografías instantáneas y la prensa invadían la vida privada. Se estableció que ni la veracidad de lo publicado ni la ausencia de malicia constituyen una defensa válida.

- **1948 → Declaración Universal de Derechos Humanos:** toda persona tiene derecho a la protección de la ley contra injerencias arbitrarias en su vida privada, su familia, su domicilio o su correspondencia.
- **1974 → Privacy Act (EEUU):** regula la recolección, mantenimiento, uso y diseminación de información sobre individuos por parte de agencias federales. Principios clave:
  - Mantener solo información relevante y necesaria.
  - Recolectar información, en la medida de lo posible, directamente del individuo.
  - Informar a los individuos cuando se les pide información.
  - Publicar un System of Records Notice (nombre y ubicación del sistema, usos rutinarios, políticas de almacenamiento, controles de acceso, retención y disposición).

## Argentina

**Ley de Protección de los Datos Personales (Ley 25.326/2000).** Los ciudadanos pueden, respecto a datos personales guardados en archivos, registros o bancos de datos públicos o privados, solicitar:

- Que sus datos no sean utilizados ni registrados sin su consentimiento.
- Que les informen qué datos personales están registrados.
- Que sus datos sean corregidos o actualizados.
- Que sean suprimidos, en los casos en que corresponda.
- Que sean guardados confidencialmente.
- Iniciar una acción judicial para conocer sus datos o exigir su rectificación, supresión, confidencialidad o actualización.

El organismo de aplicación es la **AAIP** (Agencia de Acceso a la Información Pública).

## Unión Europea

Desde 2016, la UE posee el **GDPR** (Reglamento General de Protección de Datos / General Data Protection Regulation).

## EEUU

En 2018 se introdujo el **CCPA** (California Consumer Privacy Act).

*Las filtraciones de datos son costosas y dolorosas, al igual que las multas regulatorias.*

---

## Recolección de información sensible

¿Qué son los **datos personales**? Cualquier tipo de información: datos de identidad, de domicilio, de deudas, imágenes en videos de vigilancia, datos biométricos, etc.

**Datos sensibles prohibidos** → No puede haber registros referidos al origen racial o étnico, opiniones políticas, convicciones religiosas, filosóficas o morales, afiliación sindical, o datos relacionados con la salud o la vida sexual.

Formas de recolección de información sensible:

- Registros en sitios web
  - Cookies
  - Spyware
  - RFIDs, geolocalización
- 

## Data literacy

*La sociedad digital requiere de los ciudadanos la habilidad de manejar datos correctamente.* El desarrollo de estas habilidades no solo es una herramienta de inserción para los ciudadanos, sino que desde el punto de vista organizacional disminuye las posibilidades de **data leakages** y favorece el trabajo conjunto en pos de la gobernanza de datos.

**Data literacy** → la habilidad de leer, escribir y comunicar sobre datos de una manera que genere valor e impacto para la organización.

## Swampification

Ocurre cuando se depende demasiado de un data engineer o data scientist para saber dónde residen ciertos datos, quiénes son sus stakeholders y cómo podrían cambiar. Si se depende demasiado de esto, los datos se "pantanizan" (swampify): nadie puede trabajar porque la curva de aprendizaje para entender los datos es muy empinada.

## Increasing Data literacy

¿Cómo se construye una cultura de calidad de datos? Para muchas organizaciones, todo empieza con la **data literacy**. *Si no se entiende el valor de los datos, no se puede entender el valor de la calidad de datos.*

## Data literacy Strategy

Una buena estrategia de data literacy necesita buy-in de arriba hacia abajo (top-down) y adopción de abajo hacia arriba (bottoms-up), *haciendo los datos más accesibles y fáciles de trabajar*, con herramientas self-service y educación para los miembros menos técnicos del equipo. La clave es encontrarse con los stakeholders donde están.

A nivel gubernamental, se están planteando objetivos para que los ciudadanos alcancen la alfabetización de datos.