

T10.2 - Big Data (Motivación)

Las cuatro "V" del Big Data:

- **Volumen.** *La cantidad de datos generados es enorme.*

Un solo *pozo petrolero* puede generar ~1 TB de datos de producción por día, y Refinitiv recolecta más de 1 PB diario y procesa más de un millón de documentos no estructurados.

Metáfora del iceberg: solo el 20% de los datos son estructurados, mientras que el 80% es no estructurado (PDFs, videos, posts de redes sociales...)

- **Variedad.** No solo hay muchos datos, sino que vienen en *formatos muy distintos*.

Ciudad inteligente: sensores lumínicos, de energía, de concentración de NO₂, datos de tráfico georreferenciados, video en tiempo real.

"Nuevos tipos de datos": infografía de lo que pasa cada 60 segundos en internet: tweets, búsquedas en Google, emails...

- **Velocidad.** *La rapidez con la que los datos deben procesarse importa.*

High-frequency trading en Wall Street: la co-localización de servidores con el exchange permite recortar milisegundos, recortar un milisegundo por operación puede valer USD 100 millones anuales para una firma grande.

- **Veracidad.** *No todos los datos son confiables.* Dimensiones de calidad asociadas → accuracy, believability, reputation, objectivity, factuality, consistency, freedom from bias, correctness y unambiguousness. Distintas disciplinas priorizan distintas V.

Dicotomías para procesar Big Data:

- ¿Online u offline?
- ¿Batch o real-time?
- ¿Cómputo secuencial o paralelo?
- ¿Estructurado o no estructurado?
- ¿Sistemas distribuidos o centralizados?