

T10.4 - Integración de datos

Data Warehouse

¿Por qué no hacer consultas directamente a nuestra DB transaccional?

Se hace *para empresas chicas* o proyectos que recién arrancan.

Cuando el *contexto se expande*, este *approach tiene un techo*.

- Estas bases están *optimizadas para escrituras*, no *para queries analíticas*.
- Un reporte analítico pesado puede *ralentizar la experiencia de los usuarios* cuando quieran usar la aplicación en ese momento.
- *La base de datos cambia todo el tiempo*: los desarrolladores cambian datos, agregan filas, las sacan... todo acorde a las necesidades que se deben satisfacer. *Los pasos a seguir de un reporte debe cambiarse también porque la DB cambió*.

Un **data warehouse** es una base diseñada para hacer análisis, no para operar.

DB transaccional (OLTP)	Data Warehouse (OLAP)
<i>Optimizada para escritura</i> → INSERT / UPDATE	Optimizada para leer mucho de un saque
Datos <i>normalizados</i>	Datos <i>no-normalizados</i>
Estado actual → la base sabe cómo están los datos <i>ahora</i> .	Historia+estado actual → trackea <i>cómo eran los datos</i> en cierto momento.
Baja latencia por transacción	Latencia aceptable, throughput alto

Medallion

Es una *arquitectura en capas de un data warehouse* para procesar datos.


Bronze	Silver	Gold
Datos crudos salidos de la fuente	Datos limpios y conformados → estandarizados, tipificados, sin duplicados...	Datos listos para análisis → agregaciones, métricas... Star Schema.

Esta arquitectura trae como *ventajas*:

- *Reprocesamiento fácil* → estando en bronze, podés pasarte a silver o gold.
- Si un dato sale mal, se puede *saber en qué capa falló*.

- Cada capa tiene su test.
- Idempotencia.

Star schema → modelaje de la capa gold. Es una **fact table** en el centro, con dimension tables alrededor.



Las **fact table** son *tablas con muchísimas filas pero pocas columnas*, básicamente claves foráneas a las dimensiones más las métricas numéricas.

Cada fila es una venta, un click, un envío...
Cada columna es el monto, cantidad, duración...

Las **dimension tables** dan el *contexto*. Son tablas con *pocas filas pero muchas columnas descriptivas*.

Cada fila es quién compró, qué producto, cuándo, por qué canal...
Las columnas pueden ser nombre, categoría, dirección...

Si *un atributo de una dimensión cambia*, se opta entre:

1. **Pisar** → update directo sobre la fila. Se pierde rastro del valor anterior.
2. **Versionar** → nueva fila. Los reportes históricos se mantienen.

Es importante testear los datos para que los reportes no digan cosas que no son → **data quality**.

Potestad de los usuarios de confiar en los datos y saber todo acerca de ellos → **data governance**.