

TD7: Ingeniería de Datos

**Clase Práctica 10:
Apache Spark - Map Reduce**

Clase de hoy

- Apache Spark
- Map Reduce
- Ejercicio práctica A y B
(*Break*)
- Spark SQL
- Consultas

Apache Spark

Apache Spark



Es un **motor de procesamiento de datos en unificado y de código abierto**, diseñado para procesar volúmenes masivos de información (Big Data) a una velocidad increíble.

A diferencia de los sistemas antiguos que guardaban los resultados intermedios en el disco duro (lo que los hacía muy lentos), el gran superpoder de Spark es que procesa los datos directamente en la memoria RAM de un clúster (un grupo de computadoras interconectadas).

- **Procesamiento por lotes (Batch Processing):** Analizar conjuntos de datos gigantescos que ya están guardados (por ejemplo, los registros de ventas de los últimos 10 años).
- **Procesamiento en tiempo real (Streaming):** Analizar datos a milisegundos de que se generen (por ejemplo, detectar un fraude con tarjeta de crédito en el instante en que deslizas el plástico).
- **Machine Learning (MLlib):** Entrenar modelos de inteligencia artificial con miles de millones de registros de forma distribuida.
- **Consultas SQL (Spark SQL):** Permitir a analistas explorar bases de datos masivas usando el lenguaje SQL de toda la vida, combinando la facilidad del SQL con el poder del Big Data.

Map Reduce

Map Reduce

En el **map** se reciben datos de la forma (k, v) (es decir, pares clave-valor) y los *mapea* a cada uno a una lista de pares $[(k_1, v_1), (k_2, v_2)\dots]$ que se pueden calcular como función del par original (k, v) .

En el **reduce** se recibe un par de la forma

$(k, [v_1, v_2, \dots, v_n])$

(es decir, una clave y un conjunto de datos asociado a esa clave) y se los resume en un conjunto de valores $[w_1, w_2, \dots, w_m]$ (en general, es un único valor).

Ejemplo: word count

No sé qué es lo que
pasó.
Qué te parece todo
esto?
Nos vemos mañana?
Ya me fui





No sé qué es lo que

pasó Qué te parece todo

Esto? Nos vemos mañana? Ya

me fui






map



no		1
se		1
que		2
...		

paso		1
que		1
te		1
...		

reduce



Map Reduce - word count

```
def map(k, v):  
    d = dict ()  
    for word in k:  
        if (word in d.keys ()):   
            d[word] = d[word] + 1  
        else:  
            d[word] = 1  
    return d.items ()
```

```
def reduce (k, list_v):  
    freq_k = sum(list_v)  
    if freq_k >100:  
        return (k, freq_k)
```


Ejercicio A

Dada una lista de números naturales, calcular la suma total de los mismos.

Ejercicio A

Dada una lista de números naturales, calcular la suma total de los mismos.

```
def map(k, v):  
    d = dict()  
    d["total"] = v  
    return d.items()
```

```
def reduce(k, list_v):  
    return (k, sum(list_v))
```

Ejercicio A

```
def map(k, v):  
    d = dict()  
    d["total"] = v  
    return d.items()
```

```
def reduce(k, list_v):  
    return (k, sum(list_v))
```

Map

Reduce

(0, 4)	emiten	{total: 4}
(1, 6)	..	{total: 6}
(2, 45)		{total: 45}
(3, 34)	=>	{total: 34}
(4, 40)		{total: 40}
(5, 12)		{total: 12}

reduce a

{total: 141}

=>

Ejercicio B

Contar cuantas veces aparece cada letra en una frase simple, no consideramos espacios en blanco, ni mayúsculas ni minúsculas.

Ejemplo input: “Ideología aristocrática”

Ejercicio B

Contar cuantas veces aparece cada letra en una frase simple, no consideramos espacios en blanco, ni mayúsculas ni minúsculas.

Ejemplo input: “Ideología aristocrática”

```
def map(k, v):
```

```
    d = {}
```

```
    v_limpio = v.lower()
    .replace(" ", "")
    .replace("í", "i")
    .replace("á", "a")
```

```
    for letra in v_limpio:
        if letra not in d:
            d[letra] = []
        d[letra].append(1)
    return d.items()
```

```
def reduce(k, list_v):
```

```
    total_apariciones = sum(list_v)
    return (k, total_apariciones)
```

```
    ...
    map(1, "ideología")
    map(2, "aristocrática")
```

¿Qué emite cada map?
¿Cómo es el reduce?

Apache Spark SQL

Apache Spark SQL

Como dijimos, Spark tiene un módulo integrado con SQL. Es decir, permite realizar *queries* vía lenguajes de consulta, o bien apificadas en Java, Scala, Python (vía PySpark), R, etc.

Integra los beneficios de procesamiento masivo de Spark con consultas estructuradas.

Es decir, Spark se encarga internamente de resolver las consultas de lenguajes declarativos como SQL.