

TD7: Ingeniería de Datos

Calidad y Gobernanza de Datos

¿Qué es la “calidad de datos”?

Definición

⚙ La calidad de un dato es su **aptitud para ser usado** por quien debe consumirlo.

⚙ Esta aptitud se **cuantifica** y se **mide** a partir de

⚙ **Análisis univariado**

⚙ **Análisis bivariado**

⚙ **Dimensiones**


Analizando la calidad de los datos

⚙️ Análisis univariado

- ¿Cuál es el valor mínimo? ¿Y el máximo?
- Media, mediana, moda, cuartiles
- Histogramas
- Tablas de frecuencia
- Gráficos

⚙️ Análisis bivariado

- Coeficiente de correlación
- Tablas de contingencia
- Diagramas de dispersión de puntos



Dimensiones de la calidad de datos

— — —

⚙ Consideraremos las siguientes dimensiones:

- **Precisión** (Accuracy; se corresponde con la realidad)
- **Compleitud** (Completeness; no nos faltan datos)
- **Consistencia** (Consistency; no se violan las reglas de negocio)
- **Puntualidad** (Timeliness; está disponible cuando se necesita)
- **Validez** (Validity; ej. Valores en el rango correcto)
- **Unicidad** (Uniqueness; no guardamos varias veces un mismo hecho)
- **Conformidad** (Compliance; están en el formato correcto)
- **Accesibilidad** (Accessibility; disponible para los interesados)

Dimensiones de la calidad de datos

Validez: se revisan aspectos como el tipo de los datos o claves foráneas.

Nombre	Apellido	e-mail	Cód. país	Total de gastos
Juan	\$@#S#@@	hola@gmail	99	a

Respetar el tipo de datos (cadena de texto) pero no parece ser un apellido válido

@gmail no es un dominio válido

La clave foránea 99 no está presente en la tabla de países

“a” no es un monto válido

Cód. país	Nombre país
20	Argentina
21	Perú
22	Colombia

Dimensiones de la calidad de datos

— — —

Precisión: qué tan cercano a la realidad es el dato observado.

Nombre	Apellido	e-mail	Cód. país	Total de gastos
Juan	Perezz	juan.perez@gmail.com	20	\$2000



Formato correcto, pero no se corresponde con la realidad observable

Dimensiones de la calidad de datos

— — —

Compleitud: Los datos esperados no deben tener valores desconocidos.

Nombre	Apellido	e-mail	Cód. país	Total de gastos
Juan	Perez	juan.perez@gmail.com	20	[null]



Falta el total de gastos

Dimensiones de la calidad de datos

— — —

Consistencia: las reglas de negocio se mantienen y los distintos datos son coherentes entre sí.

Nombre	Apellido	e-mail	Cód. empresa	Dirección laboral
Juan	Perez	juan.perez@gmail.com	281	Av. Pres. Figueroa Alcorta 7350

Código	Razón Social	Dirección
281	UTDT	Juan Pablo Saenz Valiente 1021

No coinciden las direcciones

Gobernanza de Datos

Ciclo de vida del dato

Los datos recorren un camino desde que son adquiridos por una organización hasta que son descartados.



Gobernanza de datos

— — —

- ⚙ La **gobernanza de datos** es la capacidad de una organización de asegurar una alta calidad de los datos que maneja.
- ⚙ Implica la implementación de **procesos y prácticas** que aseguren una **gestión de datos efectiva** a través de toda la organización.

Gobernanza de datos

— — —

⚙ Abarca:

- Definición de quiénes serán **responsables** (*data steward* o supervisor de datos)
- Cómo los datos van a ser almacenados, respaldados y protegidos
- **Normas** sobre cómo serán utilizados
- Controles y procedimientos de **auditoría**

Alcanzando la calidad de datos

Pipelines de datos

— — —

- ⚙ Cada vez que hay un **pasaje de datos** entre dos subsistemas o equipos, los mismos se deberían **validar** para asegurar que se encuentran en el estado esperado.
- ⚙ Y si este pasaje se hace en **streaming**, entonces es necesario validar en forma **continua** el proceso, definiendo de antemano qué acción tomar cuando se produzca una violación de las reglas.

Observabilidad (*observability*)

- ⚙ La **observabilidad** es la comprensión que tiene una organización respecto a la salud y desempeño de los datos en sus sistemas.
- ⚙ Es una herramienta para alcanzar y mejorar la calidad de datos. Para lograrla se utilizan **técnicas** como:
 - **Monitoreo automatizado**
 - **Análisis de causa raíz** (*root cause analysis, RCA*)
 - **Linaje de datos** (*data lineage*) → poder hacer un rastreo de cómo se llega a un dato
- ⚙ El objetivo de estas técnicas es **prevenir, detectar y resolver anomalías**. Esto redundaría en:
 - Pipelines de datos más saludables
 - Mayor productividad de los equipos
 - Mejor gestión de datos
 - En última instancia, mayor satisfacción del cliente.

Detectar anomalías lo antes posible