

TD7: Ingeniería de Datos

Arquitectura lambda. Introducción

Arquitecturas Big Data



Data warehousing

VS.



Data lake



Fully incremental

VS.



Event sourcing

Habíamos planteado esta ecuación



Si un sistema de datos responde preguntas mirando datos del pasado, entonces el sistema de datos más general responde preguntas mirando el conjunto de datos completo. Así, la definición más general que podemos dar para un sistema de datos es la siguiente:

query = function(all data)

Arquitectura lambda

Arquitectura Lambda



- ❖ Arquitectura orientada a resolver los **problemas de fully incremental y event sourcing** para casos de uso no triviales.
- ❖ Solución compleja que implica combinar estrategias de procesamiento **batch y real-time**
- ❖ Permite aplicar técnicas de **Big Data** a problemas que requieren **data freshness**

Arquitectura Lambda

Organizada en capas:

Cada capa satisface un subconjunto de propiedades y se basa en la funcionalidad proporcionada por las capas debajo de ella.



Speed Layer

Serving Layer

Batch Layer

Arquitectura Lambda

Organizada en capas:

Speed Layer

Serving Layer

Batch Layer

> construye *batch views*



Arquitectura Lambda

— — —

Organizada en capas:

Speed Layer

Serving Layer

> sirve batch views

Batch Layer

> construye *batch views*



Arquitectura Lambda

Organizada en capas:

Speed Layer

> construye real-time views

Serving Layer

> sirve batch views

Batch Layer

> construye *batch views*



Arquitectura Lambda



```
query = function(all data)
```

Esta función podría tomar una gran cantidad de recursos y ser muy cara. Una obvia alternativa es pre computar la función query. Llamaremos a ese pre cálculo **batch view**. Es decir que los resultados se leerán de una vista pre computada.

Arquitectura Lambda



```
query = function(all data)
```

```
batch view = function(all data)
```

Crear una **batch view** es una operación de alta latencia porque se ejecuta una función sobre toda la data. Para cuando termine, mucha nueva data recolectada no estará representada en el batch view. Para esto se crea una **realtime view** que incorpora la data que quedó afuera del batch view.

Arquitectura Lambda



```
query = function(all data)
```

```
batch view = function(all data)
```

```
realtime view = function(realtime view, new data)
```

La **arquitectura lambda** está completamente resumida en las dos últimas ecuaciones y la siguiente:

Arquitectura Lambda




~~query = function(all data)~~

batch view = function(all data)

realtime view = function(realtime view, new data)

query = function(batch view, realtime view)

Arquitectura Lambda



Arquitectura Lambda - ejemplo conceptual



- ❖ Aplicación mobile de consumo de contenido.
- ❖ Eventos relevantes generados por usuarios (plays, pausas, favoritos, agregado a listas, etc)
- ❖ Eventos relevantes de otras fuentes (nuevo contenido, ventas físicas, redes sociales)



- ❖ **Caso de uso:** Sistema de recomendación para usuarios

Arquitectura Lambda - tecnologías



— — —

El recorrido por la Arquitectura Lambda nos va a servir como excusa para ver, entre otras, estas tecnologías:

- ❖ Entornos de cómputo paralelizable (batching y streaming)
- ❖ Sistemas de almacenamiento distribuido
 - Filesystem distribuidos
 - Bases de datos NoSQL
- ❖ Frameworks de serialización de objetos
- ❖ Sistemas de colas distribuidas (y asincrónicas)

Arquitectura Lambda - ejemplo conceptual



- ❖ ¿Qué forma tienen los eventos? ¿Dónde los almacenamos?
- ❖ ¿Cómo usar los eventos para entender qué le gustó, qué no, cuánto, para cada usuario?
- ❖ ¿Cómo hacer que los eventos más antiguos tengan cada vez menos peso (los gustos cambian)?
- ❖ Pensemos un approach fully incremental
- ❖ Pensemos uno basado en event sourcing



Arquitectura Lambda - ejemplo conceptual



Solución con arquitectura lambda:

- ¿Qué hacemos con el master dataset?
- ¿Qué forma tiene el resultado de la batch layer?
- ¿Qué podemos hacer para tener data freshness en la speed layer?



Cierre



Bibliografía

 **“Big data: Principles and best practices of scalable realtime data systems”**, N. **Marz**, J. Warren, 1st edition, 2015.
 A new paradigm for Big Data: Capítulo 1