UNIVERSIDAD TORCUATO DI TELLA

TD7: Ingeniería de Datos

Álgebra relacional

Lenguajes para el modelo relacional

Lenguajes procedurales vs. declarativos

- Para interactuar con un modelo de datos necesitamos un **lenguaje**.
- Podemos clasificar a los lenguajes en dos grandes grupos:
  - Procedurales: Son aquellos que permiten definir un procedimiento a seguir para llegar a un resultado. Estos lenguajes se basan en **operadores** para manipular los datos.
  - Declarativos: Son aquellos en los que podemos definir el resultado que queremos obtener, sin especificar cómo hacerlo.

Lenguajes para el modelo relacional

- Para interactuar con el modelo relacional se utiliza en la práctica el lenguaje **SQL**, que es un lenguaje de tipo **declarativo**.
  - Es de alto nivel.
  - El usuario especifica qué resultado quiere obtener, y el gestor se ocupa de definir un procedimiento para obtenerlo y ejecutarlo.
- Sin embargo, también existen lenguajes formales para el modelo relacional.
  - El **álgebra relacional (procedural)** y el cálculo de tuplas (decl.)
  - Estudiaremos el primero porque nos dará herramientas conceptuales de importancia general en el mundo de las bases de datos.

Álgebra relacional

- El álgebra relacional fue propuesta por E. Codd en 1970.
- Define un conjunto de operadores para manipular relaciones:
  - Proyección
  - Selección
  - Unión, intersección y diferencia
  - Producto cartesiano
  - Junta
- ¿Qué es un operador en el modelo relacional?
  - Es una función cuyos operandos son una o más relaciones, y su resultado es una relación:

$$O: R_1 \times R_2 \times \ldots \times R_n \rightarrow S$$

Herramientas para la clase de hoy

RelaX: una implementación del álgebra relacional

- RelaX - Relational algebra calculator
  http://dbis-uibk.github.io/relax/
- Diseases & Symptoms dataset: link con dataset precargado

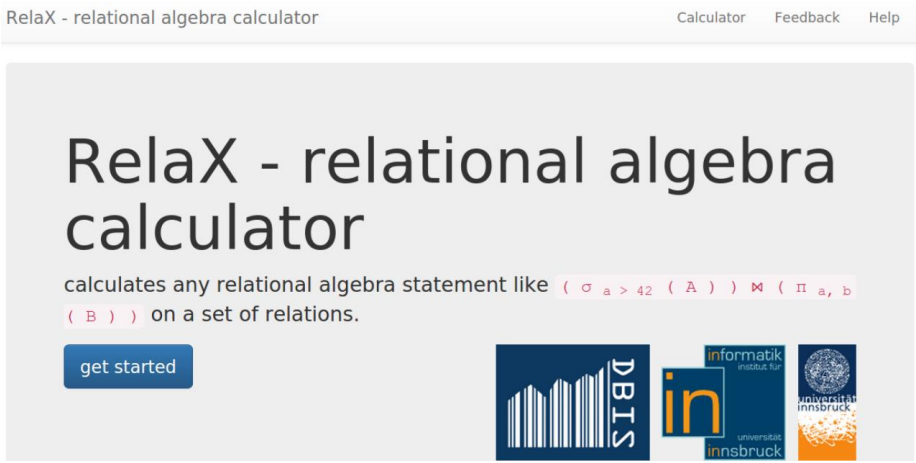

Modelo de Entidad-Interrelación

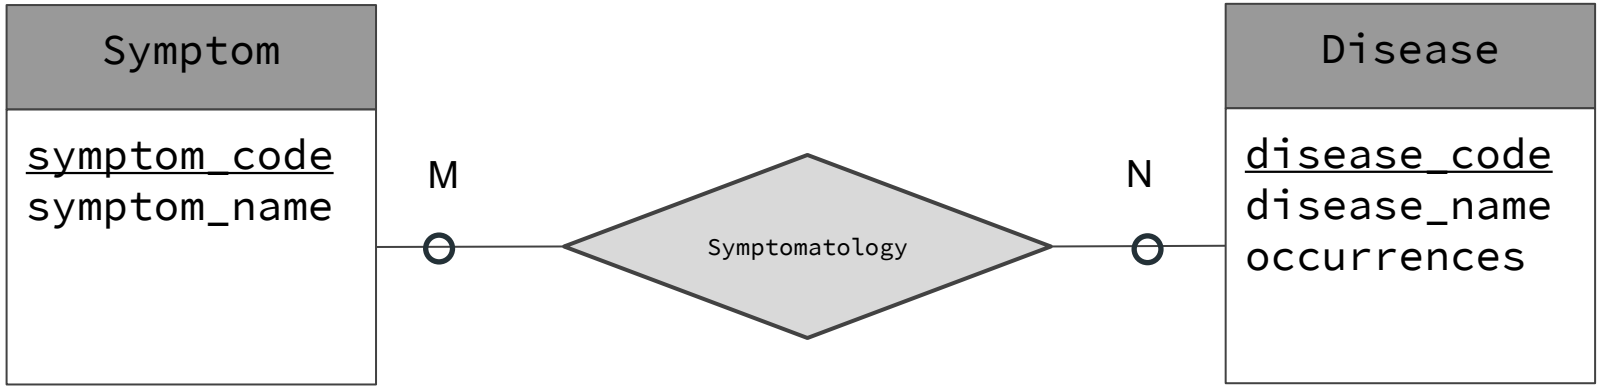

Diagrama de tablas del dataset

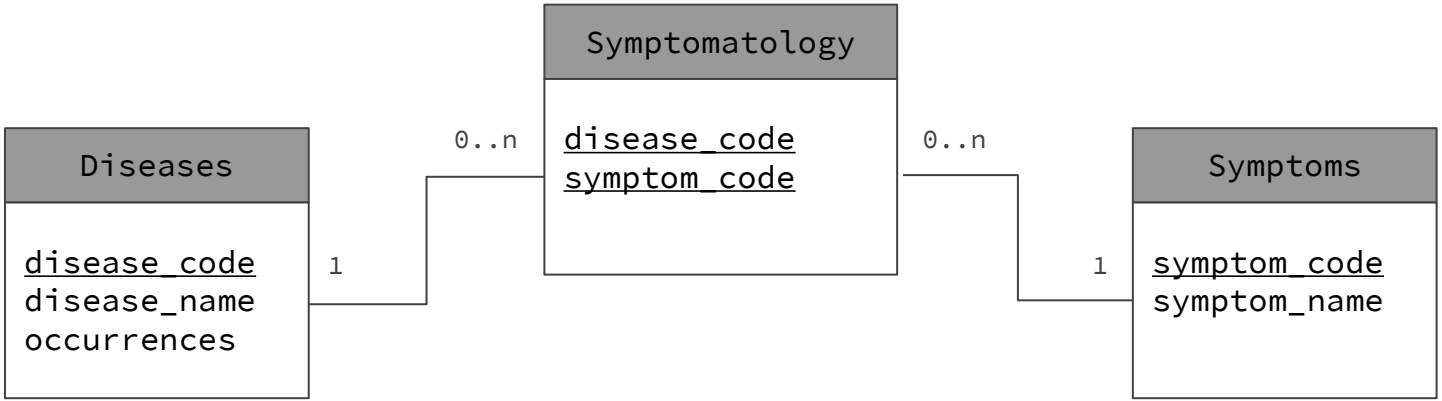

Operadores del álgebra relacional

Selección

- Supongamos una relación $R(A_1, A_2, \ldots, A_n)$.
- El operador de **selección** <u>filtra</u> las tuplas de una relación que cumplen con una determinada condición.

$$\sigma_{cond}(R) \rightarrow S$$

- ¿Qué es una condición?
  - Es una expresión booleana que se obtiene comparando atributos de esa relación y/o valores.
  - Ejemplo: $\sigma_{(A3 == 'P')}(R)$, $\sigma_{(A1 > 5)}(R)$
  - También se pueden construir condiciones más complejas usando and (∧), or (∨) y not (¬):

$$\sigma_{(cant_hijos > 0) \wedge (fecha_alta > 2024\text{-}02\text{-}29)}(Empleados)$$

Selección: ejemplo

$$\sigma_{(cant_hijos > 0) \wedge (fecha_alta > 2024\text{-}02\text{-}29)}(Empleados)$$

Empleados

legajo	apellido	fecha_alta	cant_hijos
108749	Salas	2024-03-02	1
212948	Marrone	2023-11-10	0
155109	Lucasi	2024-03-05	2
228985	Rocca	2024-02-27	4

¿Resultado?

Selección: ejemplo

$$\sigma_{(cant_hijos > 0) \wedge (fecha_alta > 2024\text{-}02\text{-}29)}(Empleados)$$

Empleados

legajo	apellido	fecha_alta	cant_hijos
108749	Salas	2024-03-02	1
212948	Marrone	2023-11-10	0
155109	Lucasi	2024-03-05	2
228985	Rocca	2024-02-27	4

legajo	apellido	fecha_alta	cant_hijos
108749	Salas	2024-03-02	1
155109	Lucasi	2024-03-05	2

Selección: ejercicio

Encontrar cuál es el código y el nombre del síntoma ‘vertigo’ (en inglés, sin acento).

Selección: ejercicio

Encontrar cuál es el código y el nombre del síntoma ‘vertigo’ (en inglés, sin acento).

$$\sigma_{\texttt{symptom_name = 'vertigo'}}\ (\text{Symptoms})$$

Proyección

- Supongamos una relación $R(A_1, A_2, \ldots, A_n)$ y una lista de atributos L donde todo $L_i \in (A_1, A_2, \ldots, A_n)$.
- El operador de **proyección** produce una nueva relación donde las tuplas resultantes son las mismas tuplas de R pero excluyendo los atributos que no pertenecen a L.

$$\pi_{A1,\ A2,\ldots,\ Aj}(R) \rightarrow S$$

- Como las relaciones son conjuntos (no hay dos tuplas iguales), S puede tener menos tuplas que R.
- Al igual que la **selección**, la **proyección** también es un operador unario

Proyección: ejemplo

$$\pi_{\texttt{apellido, cant_hijos}}(\texttt{Empleados})$$

Empleados

legajo	apellido	fecha_alta	cant_hijos
108749	Salas	2024-03-02	1
212948	Marrone	2023-11-10	0
155109	Lucasi	2024-03-05	2
228985	Rocca	2024-02-27	4
300145	Salas	2025-01-02	1

¿Resultado?

Proyección: ejemplo

$$\pi_{\texttt{apellido, cant_hijos}}(\texttt{Empleados})$$

Empleados

legajo	apellido	fecha_alta	cant_hijos
108749	Salas	2024-03-02	1
212948	Marrone	2023-11-10	0
155109	Lucasi	2024-03-05	2
228985	Rocca	2024-02-27	4
300145	Salas	2025-01-02	1

apellido	cant_hijos
Salas	1
Marrone	0
Lucasi	2
Rocca	4

Proyección

- Dijimos que en el álgebra relacional un operador es una función cuyos operandos son una o más relaciones y su resultado es una relación:

$$O: R_1 \times R_2 \times \ldots \times R_n \rightarrow S$$

- El resultado de un operador puede ser el operando de otra y, por lo tanto, estas operaciones pueden componerse:

$$\pi_{\text{apellido, cant_hijos}} (\sigma_{(\text{cant_hijos} > 0) \wedge (\text{fecha_alta} > 2024\text{-}02\text{-}29)}(\text{Empleados}))$$

Proyección: ejemplo

$$\pi_{\texttt{apellido, cant_hijos}}\left(\sigma_{\texttt{(cant_hijos > 0)} \wedge \texttt{(fecha_alta > 2024-02-29)}}(\texttt{Empleados})\right)$$

Empleados

legajo	apellido	fecha_alta	cant_hijos
108749	Salas	2024-03-02	1
212948	Marrone	2023-11-10	0
155109	Lucasi	2024-03-05	2
228985	Rocca	2024-02-27	4

¿Resultado?

Proyección: ejemplo

$\pi_{\texttt{apellido, cant_hijos}}(\sigma_{\texttt{(cant_hijos > 0) } \wedge \texttt{ (fecha_alta > 2024-02-29)}}(\texttt{Empleados}))$

Empleados

legajo	apellido	fecha_alta	cant_hijos
108749	Salas	2024-03-02	1
212948	Marrone	2023-11-10	0
155109	Lucasi	2024-03-05	2
228985	Rocca	2024-02-27	4

apellido	cant_hijos
Salas	1
Lucasi	2

Proyección: ejercicio

Encontrar código y nombre de las enfermedades con menos de 50 ocurrencias.

Proyección: ejercicio

Encontrar código y nombre de las enfermedades con menos de 50 ocurrencias.

$$\pi_{\texttt{disease_code,disease_name}}(\sigma_{\texttt{occurrences}<50}(\texttt{Diseases}))$$

Unión

- Supongamos dos relaciones $R(\{t_1, t_2, \ldots, t_n\})$ y $S(\{t_1, t_2, \ldots, t_n\})$
- Que tienen la misma **cantidad de atributos** (grado o aridad de la relación)
- Donde el **dominio** de cada enésimo atributo en R coincide con el del enésimo atributo en S ($dom(R_i) = dom(S_i)$ o compatibilidad de tipo).
- El operador binario **unión** produce una nueva relación donde las tuplas resultantes son todas las tuplas de R **y** todas las tuplas de S (sin repetidos, por tratarse de un conjunto).
- Es decir que se trata del operador de álgebra de conjuntos **unión**:

$$R \cup S$$

Unión

- Nuevamente, podemos componer operadores:

$$\sigma_{(\texttt{cant_hijos} > 0)}(\text{Empleados}) \cup \sigma_{(\texttt{fecha_alta} > 2023\text{-}02\text{-}29)}(\text{Empleados})$$

- Cuál sería el resultado de usar el operador **unión** así:

$$\pi_{\texttt{apellido, cant_hijos}}(\text{Empleados}) \cup \pi_{\texttt{legajo}}(\text{Empleados})$$

Unión: ejercicio

Encontrar el código de enfermedad de todas las enfermedades con más de 300 ocurrencias o que presentan el síntoma con código ‘UMLS:C0027497’

Unión: ejercicio

Encontrar el código de enfermedad de todas las enfermedades con más de 300 ocurrencias o que presentan el síntoma con código ‘UMLS:C0027497’

$$\pi_{disease_code}(\sigma_{occurrences>300}(Diseases)) \cup \pi_{disease_code}(\sigma_{symptom_code='UMLS:C0027497'}(Symptomatology))$$

Diferencia / Intersección

- Las operaciones de conjunto de **diferencia** (-) y de **intersección** (∩) también pueden usarse en el álgebra relacional
- La **diferencia** $R - S$ va a dar como resultado todas las tuplas de R que **no** se encuentran en S.
- La **intersección** $R \cap S$ va a dar como resultado sólo las tuplas de R que **además** se encuentran en S.
- Al igual que la **unión**, **diferencia** e **intersección** requieren igualdad de grado y compatibilidad de tipo.

Diferencia: ejercicio

Encontrar el código de enfermedad de las enfermedades que no presentan el síntoma con código ‘UMLS:C0232257’ y tienen menos de 50 ocurrencias

Diferencia: ejercicio

Encontrar el código de enfermedad de las enfermedades que no presentan el síntoma con código 'UMLS:C0232257' y tienen menos de 50 ocurrencias

$$\pi_{disease_code}(\sigma_{occurrences<50}(Diseases)) -$$

$$\pi_{disease_code}(\sigma_{symptom_code=\ 'UMLS:C0232257'}(Symptomatology))$$

Producto cartesiano

- Dadas dos relaciones $R(A_1, A_2, \ldots, A_n)$ y $S(B_1, B_2, \ldots, B_n)$, el **producto cartesiano** $R \times S$ produce una nueva relación T cuyas tuplas van a ser todas las combinaciones posibles entre tuplas de R y tuplas de S.

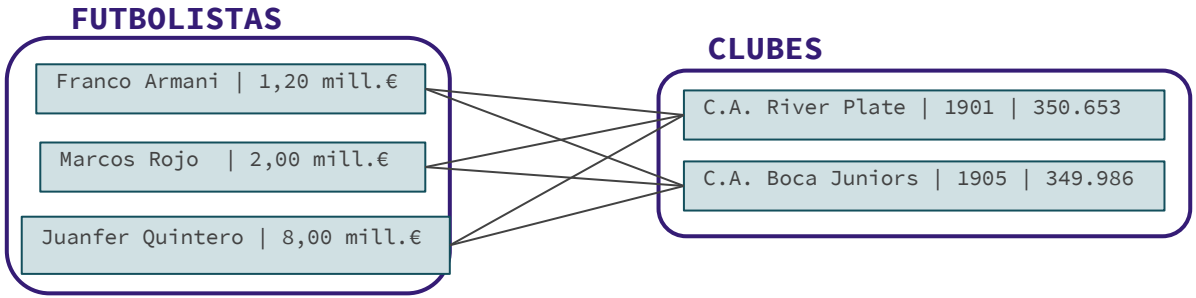

Producto cartesiano

- Dadas dos relaciones $R(A_1, A_2, \ldots, A_n)$ y $S(B_1, B_2, \ldots, B_n)$, el **producto cartesiano** $R \times S$ produce una nueva relación T cuyas tuplas van a ser todas las combinaciones posibles entre tuplas de R y tuplas de S.

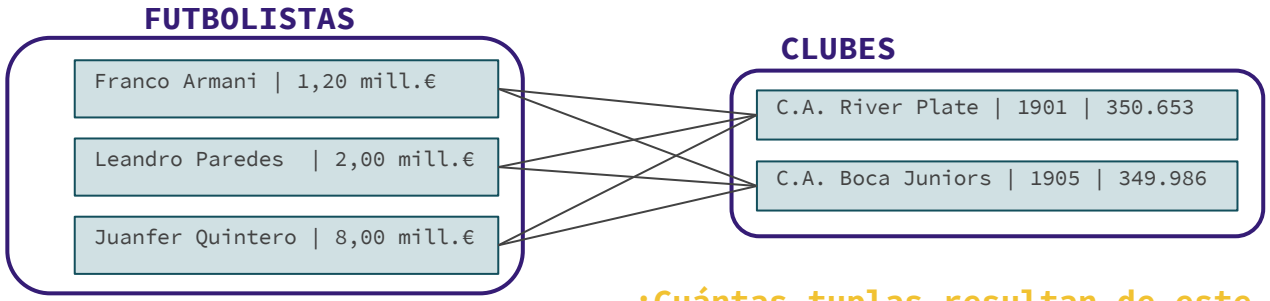

¿Cuántas tuplas resultan de este producto?

Producto cartesiano

- Los atributos de T van a ser la suma de los atributos de R y los de S, de la forma $T(A_1, A_2, \ldots, A_n, B_1, B_2, \ldots, B_n)$.
- La única excepción es cuando un atributo de R, A_i y otro de S, B_j tienen el mismo nombre, en cuyo caso pasarán a llamarse $R.A_i$ y $S.B_j$.
- El **producto cartesiano** no requiere igualdad de grado ni compatibilidad de tipos

Producto cartesiano

FUTBOLISTAS × CLUBES

Franco Armani	1,20 mill.€	C.A. River Plate	1901	350.653
Leandro Paredes	2,00 mill.€	C.A. River Plate	1901	350.653
Juanfer Quintero	8,00 mill.€	C.A. River Plate	1901	350.653
Franco Armani	1,20 mill.€	C.A. Boca Juniors	1905	349.986
Leandro Paredes	2,00 mill.€	C.A. Boca Juniors	1905	349.986
Juanfer Quintero	8,00 mill.€	C.A. Boca Juniors	1905	349.986

Producto cartesiano: ejercicio

Encontrar los códigos de todos los síntomas que se presentan en enfermedades con más de 500 ocurrencias

Producto cartesiano: ejercicio

Encontrar los códigos de todos los síntomas que se presentan en enfermedades con más de 500 ocurrencias

$$\pi_{\texttt{Symptomatology.symptom_code}}$$

$$(\sigma_{(\texttt{Diseases.occurrences}>500 \wedge \texttt{Diseases.disease_code}=\texttt{Symptomatology.disease_code})}$$

$$(\texttt{Diseases} \times \texttt{Symptomatology}))$$

Redenominación

- El operador unario **redenominación** permite cambiarle el nombre a una relación o a sus atributos.

$$\rho_x(R)$$
$$\rho_{x(A1,A2,...,An)}(R)$$

- Es útil para preparar resultados intermedios para una operación posterior, especialmente cuando hay colisiones de nombres.

Redenominación: ejercicio

Traducir al español el nombre de la relación Diseases y sus atributos

Redenominación: ejercicio

Traducir al español el nombre de la relación Diseases y sus atributos

$$\rho_{\text{Enfermedades}}(\rho_{\text{codigo}\leftarrow\text{disease_code},\text{nombre}\leftarrow\text{disease_name},\text{ocurrencias}\leftarrow\text{occurrences}}(\text{Diseases}))$$

Operaciones adicionales

- Las operaciones básicas son suficientes para expresar cualquier consulta de álgebra relacional.
- Pero hay un conjunto de operaciones adicionales para evitar sobre complejizar algunas consultas:
  - Asignación
  - Junta
  - Junta externa

Asignación

- La **asignación** es una operación exclusivamente de conveniencia.
- Permite “guardar” expresiones para usar en operaciones posteriores.
- Puede reemplazarse por la forma extendida siempre.

```
Disease_symptoms =
σ(Diseases.disease_code=Symptomatology.disease_code)(Diseases×Symptomatology)

Symptoms_over_500 = σ(Diseases.occurrences>500)(Disease_symptoms)

Results = πSymptomatology.symptom_code(Symptoms_over_500)

πsymptom_code(Results)
```

Revisitando el producto cartesiano

- En el esquema de Enfermedades-Sintomatología-Síntoma vamos a enfocarnos en dos enfermedades: **‘decubitus ulcer’** (úlcera) y **‘failure heart congestive’** (insuficiencia cardíaca).

- **‘decubitus ulcer’** tiene tres síntomas: 'systolic murmur‘, 'frail‘ y 'fever'

- **‘failure heart congestive’** tiene siete síntomas: 'shortness of breath', 'orthopnea‘, 'jugular venous distention‘, 'rale‘, 'dyspnea‘, 'cough‘ y 'wheezing'

Revisitando el producto cartesiano

Symptomatology

disease_code	disease_name	disease_code	symptom_code	symptom_code	symptom_name
UMLS:C0011127	**decubitus ulcer**	UMLS:C0011127	UMLS:C0232257	UMLS:C0232257	**systolic murmur**
UMLS:C0011127	**decubitus ulcer**	UMLS:C0011127	UMLS:C0871754	UMLS:C0871754	**frail**
UMLS:C0011127	**decubitus ulcer**	UMLS:C0011127	UMLS:C0015967	UMLS:C0015967	**fever**
UMLS:C0018802	**failure heart congestive**	UMLS:C0018802	UMLS:C0392680	UMLS:C0392680	**shortness of breath**
UMLS:C0018802	**failure heart congestive**	UMLS:C0018802	UMLS:C0085619	UMLS:C0085619	**orthopnea**
UMLS:C0018802	**failure heart congestive**	UMLS:C0018802	UMLS:C0240100	UMLS:C0240100	**jugular venous distention**
UMLS:C0018802	**failure heart congestive**	UMLS:C0018802	UMLS:C0034642	UMLS:C0034642	**rale**
UMLS:C0018802	**failure heart congestive**	UMLS:C0018802	UMLS:C0013404	UMLS:C0013404	**dyspnea**
UMLS:C0018802	**failure heart congestive**	UMLS:C0018802	UMLS:C0010200	UMLS:C0010200	**cough**
UMLS:C0018802	**failure heart congestive**	UMLS:C0018802	UMLS:C0043144	UMLS:C0043144	**wheezing**

Revisitando el producto cartesiano

▨ Asignemos un nombre a la selección de estas dos enfermedades (**‘decubitus ulcer’** y **‘failure heart congestive’**) de Diseases:

```
ulcerAndHeart =
(σ disease_code = 'UMLS:C0011127' ∨
disease_code = 'UMLS:C0018802' (Diseases))

ulcerAndHeart
```

Revisitando el producto cartesiano

▨ ¿Qué pasa si hacemos el siguiente producto cartesiano?

ulcerAndHeart × Symptomatology

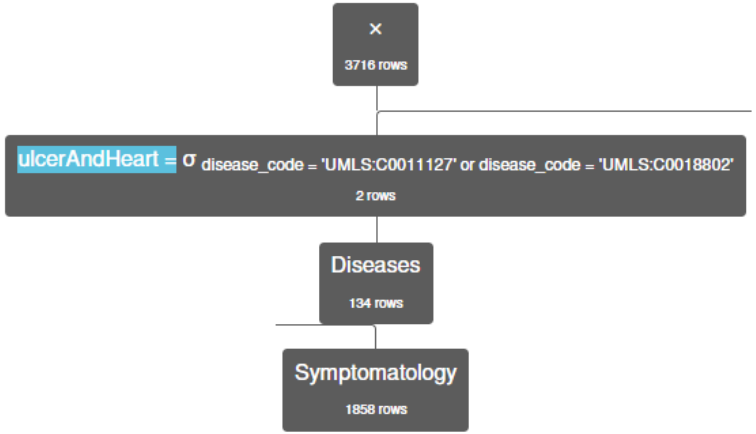

(σ disease_code = 'UMLS:C0011127' or disease_code = 'UMLS:C0018802' (Diseases)) × Symptomatology

Tiempo de consulta 1 ms

Revisitando el producto cartesiano

▨ La consulta completa correcta:

ulcerAndHeart=

(σ disease_code = 'UMLS:C0011127' ∨ disease_code = 'UMLS:C0018802' (Diseases))

σDiseases.disease_code=Symptomatology.disease_code

(ulcerAndHeart×Symptomatology)

Producto cartesiano

Encontrar los códigos de todos los síntomas que se presentan en enfermedades con más de 500 ocurrencias

Producto cartesiano

Encontrar los códigos de todos los síntomas que se presentan en enfermedades con más de 500 ocurrencias

$$\pi_{\texttt{Symptomatology.symptom_code}}$$

$$(\sigma_{(\texttt{Diseases.occurrences}>500 \wedge \texttt{Diseases.disease_code}=\texttt{Symptomatology.disease_code})}$$

$$(\texttt{Diseases} \times \texttt{Symptomatology}))$$

Junta

- Permite combinar en una sola operación un **producto cartesiano** y una **selección**.

  $$\text{Diseases} \bowtie_{\text{Diseases.disease_code=Symptomatology.disease_code}} \text{Symptomatology}$$

- Sólo acepta condiciones atómicas que incluyan atributos de las dos relaciones que toma como operandos.

- Un caso especial de **junta** es la denominada **junta natural**. En este caso, no se especifica una selección. Funciona comparando todo par de atributos con igual nombre en cada una de las relaciones.

Junta externa

- Se comporta igual que la **junta**, pero permite rescatar tuplas de una o ambas relaciones que en el caso de la junta se pierden por tener valor **nulo** en el o los atributos utilizados en la selección.
- Puede ser de tipo izquierdo ($⟕$, preserva tuplas del operando izquierdo), derecho ($⟖$, preserva tuplas del operando derecho) o completo ($⟗$, preserva tuplas de ambas relaciones)

EMPLOYEE

EMPLOYEE NUMBER	MANAGER EMPLOYEE NUMBER	DEPARTMENT NUMBER	JOB CODE	LAST NAME	FIRST NAME	HIRE DATE	BIRTH DATE	SALARY AMOUNT
PK	FK	FK	FK					
1006	1019	301	312101	Stein	John	861015	631015	3945000
1008	1019	301	312102	Kanieski	Carol	870201	680517	3925000
1005	0801	403	431100	Ryan	Loretta	861015	650910	4120000
1004	1003	401	412101	Johnson	Darlene	861015	560423	4630000
1007			432101	Villegas	Arnando	870102	470131	5970000
1003	0801	401	411100	Trader	James	860731	570619	4785000

DEPARTMENT

DEPARTMENT NUMBER	DEPARTMENT NAME	BUDGET AMOUNT	MANAGER EMPLOYEE NUMBER
PK			FK
501	marketing sales	80050000	1017
301	research and development	46560000	1019
302	product planning	22600000	1016
403	education	93200000	1005
402	software support	30800000	1011
401	customer support	98230000	1003
201	technical operations	29380000	1025

1. Name the department in which James Trader works.
2. Who manages the Education Department?
3. Identify by name an employee who works for James Trader.
4. James Trader manages which department?

Employees having invalid department numbers.
(OUTER)

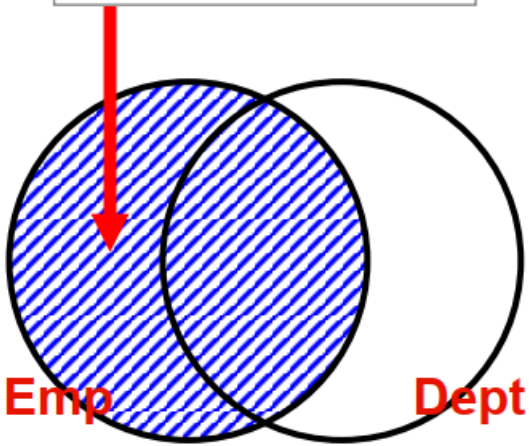

Employees and their departments
-or-
Departments and their employees
(INNER)

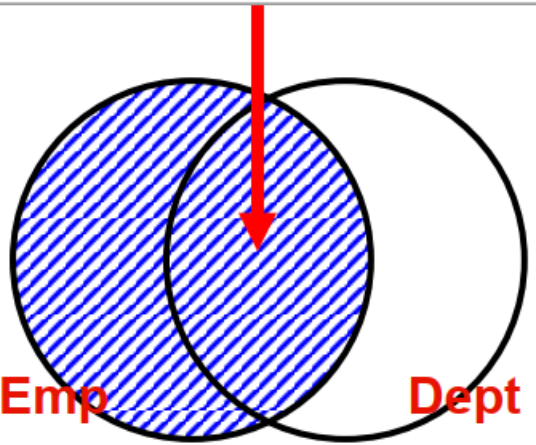

Departments having no employees
(OUTER)

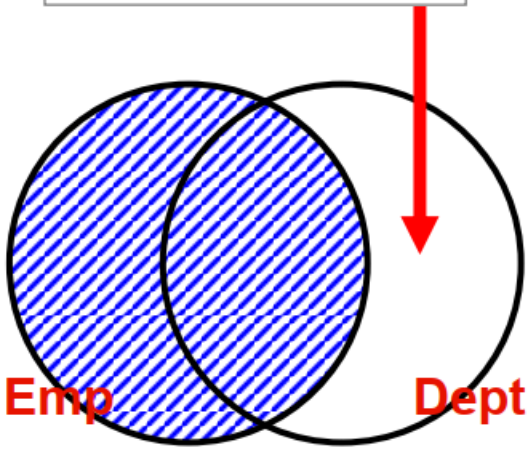

Junta externa: ejercicio

Devolver todos los nombres de los síntomas con los códigos de las enfermedades en las que aparecen, incluyendo aquellos síntomas que no se expresen en ninguna enfermedad

Junta externa: ejercicio

Devolver todos los nombres de los síntomas con los códigos de las enfermedades en las que aparecen, incluyendo aquellos síntomas que no se expresen en ninguna enfermedad

$$\pi_{\texttt{symptom_name,disease_code}}(\texttt{Symptoms} ⟕ \texttt{Symptomatology})$$

Resumen

- El **álgebra relacional** es un lenguaje procedural que permite expresar consultas en el modelo relacional.
- Define **operadores** unarios y binarios que operan con relaciones y se resuelven también como relaciones, y por tanto pueden combinarse.
- Vimos los operadores:
  - Selección: σ
  - Proyección: π
  - Unión: $\cup$
  - Diferencia: $-$
  - Intersección: $\cap$
  - Producto cartesiano: $\times$
  - Redenominación: ρ
  - Asignación: $\leftarrow$
  - Junta: $\bowtie$
  - Junta externa: $⟕$, $⟖$, $⟗$

📚 Bibliografía

📖 **[DSC19] “Database System Concepts”**, A. **Silberschatz**, H. Korth, S. Sudarshan, 2019

📌 Álgebra relacional: Capítulo 2, sección 2.6