

TD7: Ingeniería de Datos

Calidad y Gobernanza de Datos

¿Qué es la “calidad de datos”?

Definición

⚙ La calidad de un dato es su **aptitud para ser usado** por quien debe consumirlo.

⚙ Esta aptitud se **cuantifica** y se **mide** a partir de


- ⚙ **Análisis univariado**

- ⚙ **Análisis bivariado**

- ⚙ **Dimensiones**

Consecuencias de una mala calidad de datos

— — —




Analizando la calidad de los datos

⚙️ Análisis univariado

- ¿Cuál es el valor mínimo? ¿Y el máximo?
- Media, mediana, moda, cuartiles
- Histogramas
- Tablas de frecuencia
- Gráficos

⚙️ Análisis bivariado

- Coeficiente de correlación
- Tablas de contingencia
- Diagramas de dispersión de puntos



Dimensiones de la calidad de datos

— — —

⚙ Consideraremos las siguientes dimensiones:

- Precisión (Accuracy)
- Completitud (Completeness)
- Consistencia (Consistency)
- Puntualidad (Timeliness)
- Validez (Validity)
- Unicidad (Uniqueness)
- Conformidad (Compliance)
- Accesibilidad (Accessibility)

Dimensiones de la calidad de datos

— — —

⚙ Consideraremos las siguientes dimensiones:

- Precisión (Accuracy; se corresponde con la realidad)
- Completitud (Completeness; no nos faltan datos)
- Consistencia (Consistency; no se violan las reglas de negocio)
- Puntualidad (Timeliness; está disponible cuando se necesita)
- Validez (Validity; ej. Valores en el rango correcto)
- Unicidad (Uniqueness; no guardamos varias veces un mismo hecho)
- Conformidad (Compliance; están en el formato correcto)
- Accesibilidad (Accessibility; disponible para los interesados)

Dimensiones de la calidad de datos

— — —

Validez

Nombre	Apellido	e-mail	Cód. país	Total de gastos
Juan	\$@#\$#@	hola@gmail	99	a

Cód. país	Nombre país
20	Argentina
21	Perú
22	Colombia

Dimensiones de la calidad de datos

Validez: se revisan aspectos como el tipo de los datos o claves foráneas.

Nombre	Apellido	e-mail	Cód. país	Total de gastos
Juan	\$@#\$#@	hola@gmail	99	a

Respetar el tipo de datos
(cadena de texto) pero no
parece ser un apellido válido

@gmail no es un dominio válido

La clave foránea 99 no está
presente en la tabla de países

“a” no es un monto
válido

Cód. país	Nombre país
20	Argentina
21	Perú
22	Colombia

Dimensiones de la calidad de datos

— — —

Precisión

Nombre	Apellido	e-mail	Cód. país	Total de gastos
Juan	Perezz	juan.perez@gmail.com	20	\$2000

Dimensiones de la calidad de datos

— — —

Precisión: qué tan cercano a la realidad es el dato observado.

Nombre	Apellido	e-mail	Cód. país	Total de gastos
Juan	Perezz	juan.perez@gmail.com	20	\$2000



Formato correcto, pero no se corresponde con la realidad observable

Dimensiones de la calidad de datos

— — —

Compleitud

Nombre	Apellido	e-mail	Cód. país	Total de gastos
Juan	Perez	juan.perez@gmail.com	20	[null]

Dimensiones de la calidad de datos

— — —

Compleitud: Los datos esperados no deben tener valores desconocidos.

Nombre	Apellido	e-mail	Cód. país	Total de gastos
Juan	Perez	juan.perez@gmail.com	20	[null]



Falta el total de gastos

Dimensiones de la calidad de datos

— — —

Consistencia

Nombre	Apellido	e-mail	Cód. empresa	Dirección laboral
Juan	Perez	juan.perez@gmail.com	281	Av. Pres. Figueroa Alcorta 7350

Código	Razón Social	Dirección
281	UTDT	Juan Pablo Saenz Valiente 1021

Dimensiones de la calidad de datos

— — —

Consistencia: las reglas de negocio se mantienen y los distintos datos son coherentes entre sí.

Nombre	Apellido	e-mail	Cód. empresa	Dirección laboral
Juan	Perez	juan.perez@gmail.com	281	Av. Pres. Figueroa Alcorta 7350

Código	Razón Social	Dirección
281	UTDT	Juan Pablo Saenz Valiente 1021

No coinciden las direcciones

Casos reales

[Products](#) ▾[Solutions](#) ▾[Consulting](#)[Support](#) ▾[Think](#)[Think](#)[Artificial intelligence](#)[Cloud](#)[Security](#)[Sustainability](#)[Blog](#) ▾

The Impact of Bad Data and Why Observability is Now Imperative

Unity, 2022

— — —



- ⚙️ Unity cuenta con un modulo Audience Pinpointer, que permite que quien desarrolla un juego pueda promocionarlo a jugadores que puedan estar interesados. Sirve para gastar mejor el presupuesto de marketing, enfocando las campañas de anuncios en los usuarios que más probabilidades tienen de convertirse en jugadores.
- ⚙️ Una **mala ingesta de datos** de un cliente grande rompió el entrenamiento de un modelo de ML predictivo.

Unity, 2022



- ⚙ Resultado: acciones bajan un 37%, pérdida de 110 millones de dólares.
- ⚙ Prometieron desarrollar sistemas y procesos de monitoreo, alerta y recuperación para mitigar rápidamente futuros problemas de este tipo.

Casos de COVID-19 no reportados, 2020

— — —



Public Health
England

⚙ La agencia de salud estatal de Gran Bretaña omite 15.000 casos positivos en sus reportes diarios.

⚙ Los desarrolladores estaban utilizando el viejo **formato** XLS de hoja de cálculo, que solo soportaba 64k filas.

Los CSV's que las agencias le enviaban a Public Health UK para consolidación y reporte totalizaban más que eso, con lo cual el excedente se perdía.

Casos de COVID-19 no reportados, 2020



Public Health
England

Under-reported figures

From 25 Sept to 2 Oct

50,786

Cases initially reported by PHE

15,841

Unreported cases, missed due to IT error

8 days of incomplete data

1,980 cases per day, on average,
were missed in that time

48 hours Ideal time limit for
tracing contacts after positive test

Source: PHE and gov.uk

⚙ Resultado: unas posibles 15.000 personas infectadas no fueron advertidas por el sistema de rastreo de contactos, con el potencial riesgo en un momento en que aún no había siquiera vacunas.

When NASA Lost a Spacecraft Due to a Metric Math Mistake

— — —

- ⚙ El 23 de septiembre de 1999, después de casi diez meses de un arduo viaje hasta Marte, los ingenieros de la NASA se preparaban para colocar la sonda Mars Climate Orbiter en la órbita de Marte. Con todo listo para celebrar el éxito de la misión la sonda se ocultó detrás del planeta y nunca volvió a salir, perdieron el control del artefacto y este acabó estrellándose en Marte. **Alguien se olvidó de hacer la conversión del sistema imperial al métrico**, un olvido de [125 millones de dólares](#).

Gobernanza de Datos

Ciclo de vida del dato

— — —

Los datos recorren un camino desde que son adquiridos por una organización hasta que son descartados.



Gobernanza de datos

— — —

- ⚙ La **gobernanza de datos** es la capacidad de una organización de asegurar una alta calidad de los datos que maneja.
- ⚙ Implica la implementación de **procesos y prácticas** que aseguren una gestión de datos efectiva a través de toda la organización.

Gobernanza de datos

— — —

⚙ Abarca:

- Definición de quiénes serán **responsables** (*data steward* o supervisor de datos)
- Cómo los datos van a ser almacenados, respaldados y protegidos
- **Normas** sobre cómo serán utilizados
- Controles y procedimientos de **auditoría**

Alcanzando la calidad de datos

Pipelines de datos



- ⚙ Cada vez que hay un **pasaje de datos** entre dos subsistemas o equipos, los mismos se deberían **validar** para asegurar que se encuentran en el estado esperado.
- ⚙ Y si este pasaje se hace en **streaming**, entonces es necesario validar en forma **continua** el proceso, definiendo de antemano qué acción tomar cuando se produzca una violación de las reglas.

Observabilidad (*observability*)

- ⚙ La **observabilidad** es la comprensión que tiene una organización respecto a la salud y desempeño de los datos en sus sistemas.
- ⚙ Es una herramienta para alcanzar y mejorar la calidad de datos. Para lograrla se utilizan **técnicas** como:
 - **Monitoreo automatizado**
 - **Análisis de causa raíz** (*root cause analysis, RCA*)
 - **Linaje de datos** (*data lineage*) → poder hacer un rastreo de cómo se llega a un dato
- ⚙ El objetivo de estas técnicas es **prevenir, detectar y resolver anomalías**. Esto redundará en:
 - Pipelines de datos más saludables
 - Mayor productividad de los equipos
 - Mejor gestión de datos
 - En última instancia, mayor satisfacción del cliente.

Observabilidad (*observability*)


- ⚙ Es importante que las anomalías en los datos sean detectadas lo más rápido posible.



Herramientas de desarrollo

Herramientas de desarrollo

— — —




⚙ Great Expectations (GX)

- Se integra con diversas plataformas (AWS, Google Cloud, PostgreSQL, Jupyter, ...)
- Disponible tanto como solución **open-source** como *on-cloud*.
- El usuario define **expectations**: afirmaciones verificables sobre los datos que la herramienta monitoreará en forma continua. Ejemplo: “La fecha de la factura debe ser no nula en al menos el 95% de los casos”.

Herramientas de desarrollo

— — —




⚙ Great Expectations (GX)

- “lleva la computación a los datos”: utiliza Python para ejecutarse en forma nativa en cada lenguaje con que se integra. Realiza consultas nativas en esa plataforma para implementar las “Expectations” que debe monitorear.
- No es...
 - Un framework para desarrollar pipelines de ejecución (aunque se integra con ellos)
 - Un gestor de base de datos


Herramientas de desarrollo

— — —



⚙️ Great Expectations (GX)

➤ Pasos:



- Se puede configurar la periodicidad de las validaciones. Cuando una de las expectations no se cumple al momento de la validación, se puede configurar una acción, como por ejemplo:
 - Mandar un mail
 - Mandar un mensaje a un canal de Slack

Herramientas de desarrollo

— — —



DataHub

DataHub

- Framework *open-source*.
- Surgió en LinkedIn
- Escrito en Java
- Expone RESTful APIs
- Manejo de metadata
- Data discovery
- Soporte para Data Governance y Data Lineage

Herramientas de desarrollo

— — —



Alation

- Producto SaaS.
- Permite señalar problemas de data health, y definir políticas de gobernanza de datos a nivel organización.

Cierre

Bibliografía

— — —

 **“Readings in Database Systems”**, P. Bailis, JM. Hellerstein, Michael Stonebraker, 2015

 [Chapter 12: “A Biased Take on a Moving Target: Data Integration”, por Michael Stonebraker](#)



Leer!

 **“Data Quality Fundamentals”**, B. Moses, L. Gavish, M. Vorwerck, 2022 <https://www.oreilly.com/library/view/data-quality-fundamentals/9781098112035/>