TD7 — Ingeniería de Datos

Universidad Torcuato Di Tella

Examen — Modelo 2

Bloques 1, 2 y 4 — *Parte en papel*

Duración: 2 horas | Dejar las máquinas de lado

Instrucciones: Responda todos los ejercicios en papel. Justifique cada respuesta. No está permitido el uso de material de consulta ni de dispositivos electrónicos. Indique claramente el número de bloque y sub-ítem.

Bloque	**Puntaje**	**Aprueba con**
Bloque 1 — DER	10 puntos	$\geq 5/10$
Bloque 2 — Normalización + Concurrencia	4 puntos	$\geq 2/4$ (equiv. a 5/10)
Bloque 4 — Preguntas Teóricas	3 puntos	$\geq 1{,}5/3$ (equiv. a 5/10)

Bloque 1 — Diseño de DER (10 puntos)

Una plataforma de e-commerce desea modelar su sistema. Las reglas de negocio son:

- Los **vendedores** tienen un identificador único, nombre, email y fecha de registro en la plataforma.
- Los **productos** tienen un código, nombre, descripción y precio. Cada producto pertenece a exactamente una **categoría**. Una categoría tiene un código, nombre y descripción. Una categoría puede existir aunque no tenga productos asignados.
- Cada producto es publicado por *exactamente un* vendedor; un vendedor puede publicar varios productos o ninguno.
- Los **compradores** se identifican por un ID y tienen nombre, email y dirección de envío.
- Un comprador puede realizar uno o más **pedidos**. Cada pedido tiene un número único, fecha y estado (`pendiente`, `despachado`, `entregado`). Un pedido incluye uno o más productos con una cantidad determinada y el precio vigente al momento de la compra (puede diferir del precio actual del producto).
- Un comprador puede escribir **reseñas** de productos que haya comprado. Cada reseña tiene un puntaje (entero de 1 a 5) y un texto opcional. Un comprador puede reseñar un mismo producto como máximo una vez.

a) (7 pts) Dibuje el DER completo. Indique entidades, atributos (marcando el identificador de cada entidad), interrelaciones, cardinalidades y tipos de participación (total o parcial).

b) (3 pts) Traduzca el DER al modelo relacional. Para cada tabla indique nombre, todos sus atributos, clave primaria (subrayada) y *claves foráneas* (en cursiva, indicando la tabla referenciada). Preste especial atención a la relación de pedido-producto (con atributos propios).

Bloque 2 — Normalización y Concurrencia (4 puntos)

Ejercicio 2A — Normalización (1,5 puntos)

Se tiene la siguiente relación sin normalizar:

VENTA(`nro_venta, cod_producto, fecha, cod_cliente, nombre_cliente, descripcion_producto, precio_unitario, cantidad`)

Las dependencias funcionales (DF) válidas son:

- `nro_venta` → `fecha`, `cod_cliente`
- `cod_cliente` → `nombre_cliente`
- `cod_producto` → `descripcion_producto`, `precio_unitario`
- {`nro_venta`, `cod_producto`} → `cantidad`

a) (0,5 pts) Identificar la clave primaria de **VENTA**. ¿Está la relación en 2FN? Justifique identificando las dependencias parciales si las hubiera.

b) (1 pt) Lleve la relación a **3FN**. Muestre todas las relaciones resultantes con sus atributos, clave primaria y claves foráneas. Verifique también que no queden dependencias transitivas.

Ejercicio 2B — Concurrencia y Recuperabilidad (2,5 puntos)

Se tienen tres transacciones con las siguientes operaciones:

$$T_1:\ R(A),\ R(B),\ W(A) \qquad T_2:\ R(B),\ W(B) \qquad T_3:\ R(A),\ W(C)$$

El siguiente schedule S intercala sus operaciones:

$$S:\ R_1(A),\ R_2(B),\ R_3(A),\ W_2(B),\ R_1(B),\ W_1(A),\ C_2,\ W_3(C),\ C_1,\ C_3$$

a) (0,75 pts) Identificar **todos** los pares de operaciones en conflicto en S. Construir el **grafo de precedencias**. ¿Es S serializable por conflictos? Si lo es, indique el orden serial equivalente.

b) (0,75 pts) ¿El schedule S es **recuperable**? ¿Existe riesgo de **rollback en cascada**? Analice quién leyó datos escritos por quién y en qué orden se produjeron los commits.

c) (1 pt) El sistema usa la estrategia **REDO** (actualización diferida). Al momento de la falla, el log en disco contiene:

```
(BEGIN,  T1)
(BEGIN,  T2)
(WRITE,  T2, B, 200)
(COMMIT, T2)
(WRITE,  T1, A, 500)
         <-- FALLA DEL SISTEMA AQUI
```

Formato de WRITE en REDO: (WRITE, T_i, ítem, v_{new}). El valor anterior no se almacena en el log.

¿Qué transacciones deben rehacerse y cuáles no? Describa paso a paso el proceso de recuperación e indique los valores finales de A y B en disco.

Bloque 4 — Preguntas Teóricas (3 puntos — 1 punto cada una)

a) **Almacenamiento — RAID.** Describir el funcionamiento de **RAID 0**, **RAID 1** y **RAID 5**, indicando para cada nivel sus ventajas y desventajas en términos de rendimiento, capacidad útil y tolerancia a fallos. ¿Cuál elegiría para un servidor de base de datos en producción donde la disponibilidad y la integridad de los datos son críticas? Justifique su elección.

b) **Índices — Selectividad.** ¿En qué situaciones **no** conviene crear un índice sobre un atributo y puede resultar más lento que un full scan? Relacione su respuesta con el concepto de **selectividad**. ¿Qué tipos de consultas se benefician más del uso de índices?

c) **Optimización de consultas — Estadísticas.** ¿Qué son las **estadísticas** de una tabla (por ejemplo, `n_distinct`, histogramas de distribución de valores)? ¿Cómo las usa el optimizador para estimar el costo de un plan de ejecución? ¿Qué puede ocurrir si las estadísticas están desactualizadas?