TD7 — Ingeniería de Datos

Universidad Torcuato Di Tella

Segundo Parcial — Modelo 2

Duración: 2 horas | Puntaje total: 100 puntos

Instrucciones: Responda todos los ejercicios. Justifique cada respuesta. No está permitido el uso de material de consulta ni dispositivos electrónicos.

Ejercicio 1 — Normalización (35 puntos)

Se tiene la siguiente relación sin normalizar que registra las líneas de ventas de una empresa:

VENTA(`nro_venta, fecha, cod_cliente, nombre_cliente, ciudad_cliente, cod_vendedor, nombre_vendedor, cod_producto, descripcion_producto, cantidad, precio_unitario`)

Las dependencias funcionales válidas son:

- `nro_venta` → `fecha`, `cod_cliente`, `cod_vendedor`
- `cod_cliente` → `nombre_cliente`, `ciudad_cliente`
- `cod_vendedor` → `nombre_vendedor`
- {`nro_venta`, `cod_producto`} → `cantidad`
- `cod_producto` → `descripcion_producto`, `precio_unitario`

a) (4 pts) ¿Está la relación en 1FN? Identificar la clave primaria y justificar.

b) (10 pts) ¿Está la relación en 2FN? Si no lo está, identificar las dependencias parciales e indicar las relaciones obtenidas al normalizarla a 2FN (con sus atributos, PK y FK).

c) (10 pts) ¿Las relaciones de 2FN están en 3FN? Identificar las dependencias transitivas existentes y llevar a 3FN, mostrando las relaciones finales.

d) (4 pts) ¿Las relaciones obtenidas están en BCNF? Justifique brevemente para cada una.

e) (7 pts) Verificar que la descomposición final **preserva** todas las dependencias funcionales originales. Indique en qué relación queda verificable cada DF.

Ejercicio 2 — Concurrencia (35 puntos)

Se tienen tres transacciones:

$$T_1 : R(X),\ W(Y) \qquad T_2 : R(Y),\ W(Z) \qquad T_3 : R(Z),\ W(X)$$

El siguiente schedule S intercala sus operaciones:

$$S:\ R_1(X),\ R_2(Y),\ W_1(Y),\ W_2(Z),\ R_3(Z),\ W_3(X),\ C_1,\ C_2,\ C_3$$

a) (10 pts) Identificar todos los pares de operaciones en conflicto en S. Construir el **grafo de precedencias**. ¿S es serializable por conflictos? Si lo es, indique el orden serial equivalente.

b) (8 pts) ¿El schedule S es **recuperable**? ¿Hay posibilidad de **rollback en cascada**? Justifique analizando quién lee datos escritos por quién y el orden de los commits.

c) (7 pts) Explicar el protocolo **2PL** (Two-Phase Locking). Para T_1, indicar en qué momento debe adquirir cada lock (tipo S o X) y cuándo puede liberarlos para cumplir con 2PL.

d) (10 pts) Describir con un ejemplo concreto (usando T_1, T_2 y T_3 o variaciones) cómo puede surgir un **deadlock** bajo 2PL. Dibujar el **grafo de espera** (*wait-for graph*) del escenario propuesto e indicar cómo lo detectaría el SGBD.

Ejercicio 3 — Recuperación, Backups y Almacenamiento (30 puntos)

Parte A — Recuperación con estrategia REDO (12 puntos)

El sistema utiliza la estrategia **REDO** (actualización diferida). Se tiene el siguiente log al momento de la falla:

```
(BEGIN,  T1)
(BEGIN,  T2)
(WRITE,  T1, A, 100)
(WRITE,  T2, B, 200)
(COMMIT, T2)
(WRITE,  T1, C, 300)
         <-- FALLA DEL SISTEMA AQUI
```

Formato de WRITE en REDO: (WRITE, T_i, ítem, v_{new}). El valor anterior no se almacena.

a) (4 pts) ¿Qué transacciones deben rehacerse y cuáles no? Justifique.

b) (5 pts) Describir el proceso de recuperación paso a paso. ¿Qué valores quedan en disco para A, B y C?

c) (3 pts) ¿Qué ventaja aportan los **checkpoints** en la estrategia REDO? ¿Qué se escribe en el log al realizar un checkpoint?

Parte B — Backups (8 puntos)

d) (8 pts) Explicar la diferencia entre **full dump** e **incremental dump**. Describir cómo se recuperaría una base de datos ante una falla catastrófica de disco si se cuenta con: (1) un full dump del domingo, (2) incremental dumps diarios de lunes a jueves, y la falla ocurre el viernes. ¿Qué información puede perderse y por qué?

Parte C — RAID (10 puntos)

e) (10 pts) Explicar el funcionamiento de **RAID 0**, **RAID 1** y **RAID 5**, indicando para cada uno: mecanismo, ventajas y desventajas en términos de rendimiento, capacidad y tolerancia a fallos. ¿Cuál elegiría para un servidor de base de datos de producción donde la disponibilidad y la integridad de los datos son críticas? Justifique.