

TD7 — Ingeniería de Datos

Universidad Torcuato Di Tella

Segundo Parcial — Modelo 4

Duración: 2 horas | Puntaje total: 100 puntos

Instrucciones: Responda todos los ejercicios. Justifique cada respuesta; las afirmaciones sin justificación no suman puntaje. No está permitido el uso de material de consulta ni dispositivos electrónicos.

Ejercicio 1 — Optimización en SQL Server (30 puntos)

Considere el siguiente esquema y consulta sobre una base en SQL Server:

Cliente(id_cliente, nombre, ciudad) **Venta**(id_venta, id_cliente, fecha, monto)

```
SELECT  c.ciudad, SUM(v.monto) AS total
FROM    Cliente c JOIN Venta v ON c.id_cliente = v.id_cliente
WHERE   c.ciudad = 'Rosario'
GROUP BY c.ciudad;
```

La tabla **Venta** tiene 10 millones de filas; **Cliente** tiene 50.000 filas. Existe un índice *nonclustered* sobre **Cliente.ciudad** y el índice *clustered* de cada tabla está sobre su clave primaria.

- a) (6 pts) En un plan de ejecución de SQL Server, ¿en qué dirección se lee el flujo de datos y qué representa el **porcentaje** mostrado en cada operador? Explique la diferencia entre un operador **Scan** y uno **Seek**, y cuándo cada uno es preferible.
- b) (8 pts) Para acceder a las filas de **Cliente** con **ciudad = 'Rosario'**, ¿el optimizador usará un *Index Seek* o un *Clustered Index Scan*? ¿Y para leer **Venta**? Justifique en función de la selectividad de cada predicado y de los índices disponibles.

- c) (9 pts) El optimizador debe elegir el algoritmo de **junta**. Complete y justifique: para cada algoritmo (**Nested Loops**, **Merge Join**, **Hash Join**) indique si requiere que las entradas estén ordenadas, si requiere un equi-join y en qué situación de tamaños relativos es óptimo. ¿Cuál esperaría que elija el optimizador para esta consulta y por qué?
- d) (7 pts) La consulta tiene SUM con GROUP BY. Explique la diferencia entre los operadores **Stream Aggregate** y **Hash Aggregate**. ¿Cuál exige que los datos lleguen ordenados? Si creara un índice que provea ese orden, ¿qué operador de agregación esperaría ver y por qué?

Ejercicio 2 — Integración de Datos

(25 puntos)

- a) (8 pts) Complete una tabla comparativa entre una base **transaccional (OLTP)** y un **Data Warehouse (OLAP)** en las dimensiones: optimización (escritura vs. lectura), normalización, qué información retiene (estado actual vs. historia) y perfil de latencia/throughput. Explique por qué **no** conviene correr reportes analíticos pesados directamente sobre la base transaccional de producción.
- b) (9 pts) Describa la arquitectura **Medallion** (capas **Bronze**, **Silver** y **Gold**), indicando qué contiene cada capa. Mencione dos ventajas que aporta esta organización en capas (por ejemplo, frente a errores de datos).
- c) (8 pts) Diseñe un **star schema** para la capa Gold de un *e-commerce* que necesita reportar ventas por producto, cliente, fecha y canal. Indique la **fact table** (con sus claves y métricas) y las **dimension tables**. Explique la diferencia estructural entre fact y dimension tables (filas vs. columnas). Si la dirección de un cliente cambia, ¿qué significa **pisar** vs. **versionar** y qué se pierde con cada opción?

Ejercicio 3 — Arquitectura de Datos y Sistemas Distribuidos (25 puntos)

- a) (8 pts) Contraste las estrategias **Fully Incremental** y **Event Sourcing**: qué almacena cada una, cómo responde una consulta y cuál es el problema central de cada una (tolerancia a errores humanos en una; costo/escala de almacenamiento y cómputo en la otra).
- b) (9 pts) Defina los niveles de consistencia: **fuerte**, **read-your-own-writes (RYOW)**, **de sesión** y **eventual**. Para un sistema donde un usuario actualiza su propio perfil y espera verlo actualizado al instante, pero a otros usuarios les puede llegar con retraso, ¿qué nivel alcanza y por qué?
- c) (8 pts) Enuncie el **teorema CAP** (consistencia, disponibilidad, tolerancia a particiones). Explique por qué, ante una **partición de red**, un sistema distribuido debe elegir entre CP y AP. Dé un ejemplo de aplicación donde priorizaría C sobre A y otro donde priorizaría A sobre C.

Ejercicio 4 — Anonimización y Privacidad (20 puntos)

Un hospital quiere publicar el siguiente dataset para investigación. Los atributos **Edad** y **CP** (código postal) son **cuasi-identificadores**; **Enfermedad** es el atributo **sensible**.

#	Edad	CP	Enfermedad
1	29	2000	Gripe
2	31	2001	HIV
3	27	2002	HIV
4	55	2010	Diabetes
5	58	2011	Gripe
6	52	2012	Cáncer

- a) (5 pts) Defina **PII**. Explique por qué eliminar solo el nombre y el DNI **no** garantiza el anonimato si quedan cuasi-identificadores como edad y código postal.
- b) (8 pts) Explique la técnica de **k -anonimato**. Generalizando **Edad** (en rangos) y **CP** (truncando dígitos), proponga una transformación de la tabla que logre $k = 3$. Muestre los grupos resultantes.
- c) (7 pts) Explique qué es la **ℓ -diversidad** y qué problema del k -anonimato resuelve. En la tabla original, ¿qué podría inferir un atacante sobre el grupo de los registros 2 y 3 aunque estuvieran k -anonimizados? ¿Cómo lo evitaría la ℓ -diversidad?