

# TD7 — Ingeniería de Datos

Universidad Torcuato Di Tella

## Segundo Parcial — Modelo 5

Duración: 2 horas | Puntaje total: 100 puntos

---

**Instrucciones:** Responda todos los ejercicios. Justifique cada respuesta; las afirmaciones sin justificación no suman puntaje. No está permitido el uso de material de consulta ni dispositivos electrónicos.

---

### Ejercicio 1 — Arquitectura Lambda y Master Dataset (28 puntos)

- a) (6 pts) En la arquitectura Lambda se trabaja con dos ecuaciones:

```
batch view = function(all data)    realtime view = function(realtime view, new data)
```

Explique qué representa cada una y por qué la segunda es **incremental** mientras que la primera es de **alta latencia**. ¿Por qué la speed layer puede **descartar** datos cada vez que el batch layer termina un ciclo?

- b) (7 pts) El **master dataset** es “el núcleo y fuente de la verdad” de la arquitectura. Explique por qué es la única parte que debe cuidarse especialmente y cómo permite recuperar el sistema completo si se pierden todas las vistas de la serving y la speed layer.

- c) (9 pts) Enuncie y explique las tres propiedades (no funcionales) de los datos del master dataset: **crudeza (rawness)**, **inmutabilidad** y **perpetuidad**. ¿Por qué la inmutabilidad “no tendría sentido sin la perpetuidad”? ¿Cómo aporta la inmutabilidad a la **tolerancia a fallas humanas**?

- d) (6 pts) El patrón de acceso del master dataset es **write once, read many**. A partir de él, justifique por qué un **file system distribuido** se adapta mejor como *batch layer storage* que un **key/value store**. Mencione una limitación del file system distribuido.

## Ejercicio 2 — Seguridad

(24 puntos)

- a) (7 pts) Mencione las cuatro **estrategias/técnicas** de seguridad vistas (autenticación, control de acceso, encriptación, firewalls / sistemas de detección) y explique brevemente qué problema ataca cada una. Diferencie **autenticación** de **control de acceso**.
- b) (9 pts) Explique qué es un ataque de **SQL Injection**, sobre qué debilidad de las aplicaciones se aprovecha y qué objetivos puede tener (obtener, alterar o destruir información). Dé un ejemplo concreto de una consulta vulnerable y de un input malicioso, y describa cómo se mitiga.
- c) (8 pts) Explique las **medidas de control de inferencia**. Para una base de datos estadística de población que solo expone agregados (por grupo de edad, ingresos, etc.), describa cómo un usuario podría **inferir** información confidencial de un individuo a pesar de no tener acceso directo a sus registros, y por qué esto es un problema de seguridad.

**Ejercicio 3 — Privacidad, Compliance y Anonimización (24 puntos)**

- a) (7 pts) Defina **PII** y explique qué obligaciones impone a una organización el manejo de PII bajo normativas como GDPR. ¿Qué rol cumplen los **data catalogs** para rastrear “dónde vive y fluye” la PII en los pipelines?
- b) (8 pts) Explique qué es un **data catalog** y cómo **data discovery** lo extiende hacia un entendimiento dinámico y en tiempo real del estado de los datos. Enumere los cuatro **niveles de madurez** de datos de una organización (de *data reactive* a *data fluent*).
- c) (9 pts) Describa el **proceso de anonimización**: por qué debe partir de una evaluación previa de los datos y por qué deben documentarse los detalles del proceso. Explique las técnicas de **perturbación**,  **$k$ -anonimato** y  **$\ell$ -diversidad**, dando un ejemplo de aplicación de cada una. ¿Qué es un **cuasi-identificador**?

## Ejercicio 4 — Calidad, Big Data y Password Hashing (24 puntos)

- a) (8 pts) La **calidad de datos** se define como la aptitud de un dato para ser usado por quien debe consumirlo. Explique cómo se **mide** la calidad mediante análisis **univariado** y **bivariado**, dando dos ejemplos concretos de cada uno. ¿Qué dimensión de calidad atacaría con cada tipo de análisis?
- b) (8 pts) Las cuatro “V” del Big Data incluyen la **veracidad**. Explique a qué se refiere y mencione tres de las dimensiones de calidad asociadas a la veracidad. Luego, para un escenario de *high-frequency trading*, indique cuál de las “V” es la más crítica y por qué.
- c) (8 pts) Un sistema almacena las contraseñas de sus usuarios. Explique el flujo completo de **password hashing con salting**: qué se almacena al crear la cuenta, y qué pasos ocurren al validar la contraseña en cada login. Si dos usuarios eligen exactamente la misma contraseña, ¿sus hashes almacenados serán iguales o distintos? Justifique.